

先导杯 2026 AI4S 赛题二「气象大模型轻量化」说明文档

队伍名称：宁静致远 | 赛题：Pangu-Weather 模型轻量化（国产海光 DCU） | 当前推理提交实测：96.5686
教师模型：官方 Pangu-Weather（64.22M 参数 / 1.8 GB，全程冻结，仅前向） | 学生模型：MaxViT-3D（5.195M，教师的 8.1%） | 权重血缘对象：96.1213 版最终权重

一、方案总览

本方案以官方提供的 Pangu-Weather 全量权重为唯一知识来源，通过知识蒸馏训练一个自研的 MaxViT-3D 学生模型，并在海光 DCU 上以手写 HIP 算子（含矩阵核 MFMA）完成推理部署。学生模型参数量压至教师的 8.1%，推理耗时与显存占用同步大幅下降，预测精度保持不变。

轻量化 U	38.9323 / 40	（模型 5.195M · fp16 权重 10.46 MB · 显存采样均值大幅降低）
推理时长 V	19.1978 / 20	（单样本前向 32.3 ms → 矩阵核版 24.6 ms）
预测性能 W	38.4387 / 40	（全部优化均为数值等价，W 未因优化下降）
总分	96.5686	

二、模型设计

学生模型为 U 形三段式 MaxViT-3D，输入 72 通道（69 气象通道 + 3 静态场），输出 t+6h 的 69 通道绝对气象场。

结构	patch embedding (2,16,16) → encoder(2) → downsample → bottleneck(4) → upsample → decoder(2) → patch recovery
注意力	grid 等距全局注意力 + 窗口注意力，QK-Norm + 相对位置偏置
归一化	RMSNorm (pre-norm)，FFN 为 SwiGLU (mlp_ratio = 2.0)
超参	embed_dim 96 · depths (2,4,2) · heads (6,12,6) · patch (2,16,16) · global_mode grid
参数量	parameters 4.349M + buffers 0.332M = state_dict 5.195M

特别声明：本模型不使用残差预测。学生直接输出 t+6h 的绝对气象场，不存在 输出 = 输入 + 增量 的形式。权重文件的配置中 residual: False，代码中亦无相关分支。

三、训练方案（完整）

3.1 官方数据来源与“约 900 个样本”的准确口径

训练数据均为组委会提供的官方 ERA5。Mitai 4090 与 abc66 5090 均为本队实验室服务器，只承担存储和训练计算；服务器名称和物理位置不是数据来源。数据由本人从组委会 SCNet 共享目录（包括 /work2/share/sugonhpcapp01/ERA5/old-data/data/）同步到实验室，未从非赛方公开数据源、第三方机构或其他气象模型获取预测结果。对实验室镜像与赛方共享目录中 16 个相同相对路径 H5 做过完整 SHA-256 对拍，16/16 字节一致。

口头所称“约 900 个样本”对应 Mitai 上的官方同源镜像 /data2/sunkai/era5_full，准确数量是 829 个 H5，覆盖 1980-1997 共 18 年。每个文件为官方格式 fields=(99,721,1440)、FP32、411,145,088 字节；逐年分布如下：

年份	文件数	年份	文件数	年份	文件数
1980	53	1986	50	1992	34
1981	43	1987	48	1993	36
1982	48	1988	45	1994	42
1983	44	1989	67	1995	36
1984	54	1990	86	1996	26
1985	40	1991	64	1997	13
合计					829

829 是候选数据池，不是对最终训练量的虚增描述。最终权重的第一阶段在 1980-1996 候选中受 `max_cache=300` 限制，实际缓存并训练 300 个样本；1997 年全部 13 个文件用于验证。第二阶段在 5090 上使用同一官方 ERA5 的 1980 年连续序列，当时可组成 482 个相邻 6 小时 pair；同样受 `max_cache=300` 限制，按末尾 10% 固定切分为 270 训练 pair + 30 验证 pair。训练完成后继续同步到服务器的更多官方文件没有追溯性地进入该最终权重。

通道处理完全沿用赛方定义：原始 H5 的 99 个变量按官方元数据映射为模型所需的 69 个动态气象通道，另加官方 `land_mask` / `soil_type` / `topography` 三个静态场形成 72 通道输入；归一化均值和方差也来自官方目录。未增加海温、外部再分析资料、隐藏测试集信息或其他未经授权气象信号。

3.2 最终权重的两阶段真实血缘

```

实验室 Mitai 4090
student_ratio2_mom99.pth (纯官方教师蒸馏, val_match = 92.81%)
    ↓ 严格同结构加载
实验室 abc66 5090
FT50: 14 个温度通道加入 50% 官方 ERA5 真值监督, 其余 55 通道保持纯教师监督
    ↓ epoch 21 冻结快照, val_match = 92.92669932%
snap_ft50_final.pth
    ↓ 转为 FP16 推理权重
student_fp16_10MB.pth (96.1213 版最终权重)
```

第二阶段的 epoch 21 快照转为 FP16 后作为最终推理权重。该步骤仅改变权重存储精度，不改变学生模型结构、预测目标或训练监督来源。

3.3 第一阶段：实验室 4090 纯教师蒸馏

```

python distill_cache.py \
  --opt muon --muon-lr 0.02 --muon-momentum 0.99 \
  --global-mode grid --depths 2,4,2 --heads 6,12,6 \
  --embed 96 --patch 2,16,16 --mlp-ratio 2.0 \
  --train-years 1980,...,1996 --val-years 1997 \
  --epochs 80 --max-cache 300 --amp bf16 --aug 1 \
  --residual 0 --dtp 0 --spec 0 \
  --save /data2/sunkai/student_ratio2_mom99.pth
```

该阶段仅优化学生对官方冻结 Pangu 教师输出的加权 L1，未使用真值项。83 个骨干二维权重使用 Muon (`lr=0.02`, `momentum=0.99`)，其余 158 个参数组使用 AdamW (`lr=6e-4`)；经度周期 roll 开启，BF16 训练，最终 `val_match=92.81%`。模型直接输出未来完整场 `y`，`residual=0`。

3.4 第二阶段：实验室 5090 真值续训

```
python distill_truth.py \  
  --years 1980 --epochs 35 --max-cache 300 --val-frac 0.1 \  
  --truth-alpha 0.5 --full-temp 1 --phys 0 --amp bf16 \  
  --lr 6e-5 --warmup 2 --dtp 0 \  
  --resume /data2/pangu/student_ratio2_mom99.pth \  
  --save /data2/pangu/student_truth_ft50.pth
```

加载检查为 missing=0, unexpected=0。对 2m temperature 与 13 个气压层 temperature（共 14 通道），损失为 0.5 × 教师损失 + 0.5 × 官方 ERA5 真值损失；其余 55 通道仍为纯教师蒸馏。dtp=0、phys=0，没有频域、物理头或动态通道加权。原计划 35 epoch，实际在 epoch 21 将当时断点固定为 snap_ft50_final.pth 并停止；该快照经 FP16 封装后即为最终权重。

3.5 为什么完整训练不在 DCU 上进行

- 1. 资源时序：比赛早期 DCU 资源短缺、排队困难；本队在实验室 4090 和 5090 上已经完成完整训练。训练服务器均为本队实验室自有设备，不是外部在线气象服务。
- 2. 主机内存：当时 DCU 作业可用主机内存约 59-64 GB。为避免每个 epoch 重复执行全量教师前向，训练需预先缓存输入和官方教师预测目标。仅按 FP16 计算，每样本 (72+69)×721×1440×2 字节，即 292,783,680 字节（约 279.2 MiB）；300 个训练样本加 13 个验证样本约 85.3 GiB，尚未计入 Python、DataLoader、真值副本、模型与优化器开销，因此 64 GB 无法容纳。历史 249+200 的缓存规模约 122.5 GiB，与实测约 130 GB 一致。

DCU 只用于最终目标硬件上的推理、算子编译与性能评测。此前为诊断内存限制写过 DCU 流式训练复刻脚本，但它不是最终权重的训练来源，本次提交材料已删除该组脚本，也不再把其不完整训练日志写入正式说明。

3.6 随包训练源码

文件	作用	对应阶段
distill_cache.py	官方教师输出缓存、纯教师蒸馏、Muon + AdamW、EMA 与断点保存	实验室 4090 第一阶段
distill_truth.py	连续 6h pair 构造、官方教师 + 14 温度通道 ERA5 真值续训	实验室 5090 第二阶段
muon.py	第一阶段使用的 Muon 优化器实现	实验室 4090 第一阶段
maxvit3d_student.py	训练和推理共用的学生结构定义	两阶段及部署
training/run_stage1_4090.sh	第一阶段官方资产路径、环境变量与完整启动参数	训练启动
training/run_stage2_5090.sh	第二阶段官方资产路径、环境变量与完整启动参数	训练启动

四、模型与训练优化（完整清单·最终版本）

本节先对照官方 Pangu 解释学生网络和优化器为何这样设计，再逐项列出最终权重中**实际启用**的结构优化与训练策略。总体原则不是机械缩小教师，而是保留 Pangu 有效的三维表示、局部结构、全局通信和多尺度恢复能力，同时替换最昂贵的 token、宽度、注意力调度与训练更新方式。

4.1 官方 Pangu 与轻量学生的网络优化对比

比较维度	官方 Pangu 教师	最终 MaxViT-3D 学生	优化原因与效果
角色与规模	64.22M 参数，官方全量权重约 1.8GB；作为固定教师和基线。	约 5.19M 参数，FP16 推理权重约 10.46MB；负责最终部署。	用强教师提供函数监督，把部署成本转移到小学生；学生不是外部模型，也不是无教师从零替换。
输入输出语义	72 通道输入；输出 4 个地表量和 5×13 个高空量。	输入形状、变量顺序和归一化与官方一致，直接输出完整 t+6h 气象场。	保留官方数据管线和评测语义；固定 residual=False，不把预测目标改成输入残差。
Patch 与 token	地表采用细粒度 4×4 patch，高空采用 2×4×4 patch，细节充分但 token 和激活较大。	地表水平 patch 扩为 16×16，高空采用 (2,16,16)。	注意力与激活成本首先受 token 数控制；大 patch 在几乎不增加参数的情况下大幅降低计算和显存。
宽度与深度	典型嵌入宽度 192，较重的 Earth-Specific Transformer U 形层级。	embed=96、depths=(2,4,2)、heads=(6,12,6)；每个 depth 含 local 和 global 两层。	Linear 参数与计算量近似随宽度平方增长；宽度减半后，用成对局部/全局层和中段容量补回表达。
多尺度骨干	U 形编码、中层和解码，在低分辨率建模后恢复高分辨率。	保留 U 形、下采样、上采样及 skip，把主要计算放在低 token 数中层。	多尺度是教师中必须保留的气象归纳偏置，既扩大感受野，又避免丢失锋面和近地面细节。
空间注意力	Earth-specific 3D 窗口和移位窗口，位置与 mask 设计精细，但调度和临时张量较重。	连续 block 局部窗口与等距 grid 全局稀疏注意力交替。	block 保留局部连续性；grid 把远距离 token 规则分组，以小型稠密 GEMM 建立全局联系，更适合国产加速卡。
相似度与位置	标准缩放点积，配 Earth-specific 位置偏置。	Q/K L2 归一化的余弦注意力、逐头可学习温度和轻量 3D 相对位置偏置。	小模型更易出现 logit 幅值漂移；QK-Norm 把相似度限制在 [-1,1]，温度再学习各注意力头所需锐度。
Norm 与 FFN	较传统的 LayerNorm 与普通 MLP/GELU 路径。	Pre-RMSNorm、SwiGLU，mlp_ratio=2.0。	RMSNorm 去掉中心化和偏置开销；SwiGLU 用门控提升单位参数表达，再用较小 FFN 比例控制参数和激活。
残差稳定性	依赖大模型容量和成熟训练配置。	LayerScale（初值 1e-5）和随深度递增的 DropPath。	让窄学生训练初期接近恒等映射，再逐步放大分支；随机深度降低有限样本下的过拟合。
部署权重	教师只用于监督与基线，不进入最终学生推理。	最终以 FP16 保存和推理；不做 INT8、权重重排或外部查表。	与半精度推理路径一致，减少存储和加载显存，并保持实现简单、可审计。

保留能力，替换成本：Pangu 的价值是强预测函数和正确的气象归纳偏置。学生保留三维表示、局部结构、全局通信和多尺度恢复；主要替换高 token、过宽通道、复杂移位调度及传统 block 内部组件。因此本方案不是简单裁层，而是以更低成本重新表达教师的核心能力。

4.2 优化器对比：Muon + AdamW 的参数分工

参数对象	采用方法	最终配置	为什么这样选择
官方 Pangu 教师	不设优化器	<code>eval()</code> 、关闭梯度，仅做前向。	教师是组委会提供的固定基准；训练学生时不更新教师，保证监督目标稳定且可复现。
Attention/MLP 二维矩阵	Muon	<code>lr=0.02</code> 、 <code>momentum=0.99</code> 、Nesterov，5 次 Newton-Schulz 迭代。	对动量梯度矩阵做近似极分解/正交化，压平奇异值尺度，使不同输入输出方向获得更均衡的更新，适合 Transformer 的二维 Linear 权重。
Embedding/Recovery、卷积、Norm、bias 等	AdamW	第一阶段 <code>lr=6e-4</code> 、 <code>betas=(0.9,0.95)</code> 、 <code>wd=0.05</code> ；第二阶段 <code>lr</code> 降为 <code>6e-5</code> 。	非二维参数没有自然的矩阵正交化语义；AdamW 的逐元素二阶矩估计与解耦权重衰减更稳健。
全部学生参数	共同稳定器	Warmup 后余弦退火、EMA <code>0.999</code> 、梯度裁剪 <code>1.0</code> 、BF16 autocast。	Warmup 防止 Muon 大学习率早期过冲，余弦退火负责后期收敛；EMA 降低小批量噪声，裁剪抑制极端样本梯度尖峰。

Muon 解决的数学问题：设二维梯度的动量为 M ，Muon 用 Newton-Schulz 迭代近似计算 $M(M^T M)^{-1/2}$ ，得到奇异值更均衡的更新方向；AdamW 则对每个参数元素做尺度自适应。二者不是相互替代，而是分别匹配“二维矩阵参数”和“普通参数”。实现使用 BF16 矩阵运算，无需显式 SVD。

4.2.1 训练路径对比：教师只负责监督，学生分两阶段学习

环节	实际做法	相对直接复刻 Pangu 训练的优化
教师侧	Pangu 始终冻结；训练前仅前向一次，并把目标缓存为 FP16。	不重新训练或修改教师；把每轮重复的昂贵教师计算变为每个缓存样本一次，显著提高学生训练吞吐。
阶段 1：完整能力继承	1980-1996 年候选数据训练、1997 年验证；80 epoch；69 通道官方加权 L1；Muon + AdamW。	先学习教师的完整多变量函数，避免学生一开始同时面对教师和真值两个方向而产生梯度冲突。
阶段 2：有限真值校准	从阶段 1 严格续训；仅 2m 温度和 13 个气压层温度使用 <code>0.5×教师 + 0.5×ERA5 真值</code> ，其余 55 通道仍为教师监督。	只在已验证的温度子空间突破纯蒸馏上限，不用全通道真值更新破坏已经继承的风、湿度和位势场能力。
稳定与判优	BF16、经度周期 roll、纬度面积权重、EMA、梯度裁剪；同时监控 <code>val_match</code> 和温度真值 RMSE。	分别观察“是否遗忘教师整体能力”和“是否真的更接近 ERA5”，避免单一训练损失掩盖通道退化。

4.3 A 组 · 最终生效的学生模型结构优化

#	优化项	实现、作用与取舍
M1	自研轻量 MaxViT-3D 学生	以官方 Pangu 为冻结教师，学生采用适合三维气象场的 MaxViT-3D。相较 64.22M 教师，学生唯一参数约 4.35M；权重文件按运行时状态保存约 5.195M 个值，在保持完整 69 通道预测的同时显著压缩模型。
M2	三维非重叠 Patch (2,16,16)	高空场在气压层维使用 2 层 patch、水平面使用 16×16 patch；地表场使用对应二维 patch。一次完成空间降采样和通道投影，避免在 721×1440 全分辨率上堆叠昂贵注意力。
M3	U 形多尺度骨干	encoder 后下采样，在更低 token 数的 bottleneck 完成主要全局建模，再上采样并与 encoder 特征做 skip 融合。大部分计算落在低分辨率，同时保留近地面锋面、风场和局部纹理。
M4	宽度/深度联合压缩	最终配置为 embed=96、depths=(2,4,2)、heads=(6,12,6)。每个 depth 单元由一个局部 block 和一个全局 grid block 组成，把容量集中在低分辨率中段，首尾保持较窄。
M5	局部窗口 + grid 全局注意力交替	局部窗口负责连续邻域的小尺度结构；grid 分区把空间上等距分散的 token 放入同一注意力组，低成本建立远距离联系。最终固定 global_mode=grid，没有启用 spectral 或 FPA 分支。
M6	QK-Norm 与每头温度	Query/Key 点积前做 L2 归一化，再乘每个注意力头可学习的 logit_scale。将注意力改成稳定的余弦相似度形式，降低轻量网络和混合精度训练中的幅值漂移。
M7	Pre-RMSNorm	注意力与 FFN 前使用 RMSNorm，只归一化均方根而不计算均值；相较 LayerNorm 运算更少，并保持深层轻量网络的梯度尺度稳定。
M8	SwiGLU + mlp_ratio=2.0	FFN 使用门控 SwiGLU，隐藏宽度从常见的 4.0 倍压至 2.0 倍；门控非线性补偿宽度下降带来的表达损失，同时减少参数、激活显存和 GEMM 时间。
M9	LayerScale + DropPath	每个注意力和 FFN 残差分支使用可学习 LayerScale，随机深度按网络深度递增。训练早期控制分支幅值、缓解深层优化震荡；推理时 DropPath 自动关闭，不增加随机性。
M10	官方 I/O 模块兼容	Patch embedding/recovery 与官方 Pangu 的输入输出布局保持一致：输入为 69 个动态场加 3 个官方静态场，输出为 4 个地表量和 5×13 个高空量。无需裁剪预测通道即可直接使用官方评测。
M11	直接预测完整未来场	学生直接输出 t+6h 的完整绝对气象场 y，训练与推理均固定 residual=False。内部 Transformer 的普通层间残差只用于优化网络，不改变最终预测语义。
M12	FP16 部署权重	训练快照转为 FP16 推理权重，文件约 10.46MB；不做 INT8 权重量化、不重排权重、不引入查表文件，在大幅降低存储和加载显存的同时保留半精度推理路径。

4.4 B 组 · 最终生效的训练策略优化

#	优化项	实现、作用与最终配置
T1	两阶段课程式训练	第一阶段先用官方教师建立完整 69 通道能力；第二阶段从第一阶段权重严格续训，只对温度通道引入官方真值。先学习教师整体函数，再校准教师相对真值的温度偏差，降低直接混合多目标造成的互相干扰。
T2	冻结教师 + 一次性目标缓存	官方 Pangu 教师全程 eval、关闭梯度，仅在训练前做前向并把教师目标缓存为 FP16。后续 epoch 不重复运行教师，显著提高训练吞吐；这也是完整训练需要实验室大内存服务器的原因。
T3	第一阶段纯教师蒸馏	4090 阶段 80 epoch，只最小化学生与官方教师之间的加权 L1；训练 1980-1996 候选数据，max_cache=300，1997 年 13 个样本验证。先保证全部输出通道对教师稳定对齐。
T4	14 温度通道有限真值校准	5090 阶段对 2m temperature 与 13 个气压层 temperature 使用 0.5×教师损失 + 0.5×官方 ERA5 真值损失；其余 55 通道保持纯教师监督，防止真值微调破坏风、湿度和位势场。
T5	变量与层级加权 L1	地表和高空变量使用逐通道权重，地表损失整体乘 0.25、高空损失乘 1.0，使不同量纲、不同层级的变量在总梯度中保持合理比例，避免高数值幅度变量垄断更新。
T6	球面纬度面积加权	损失乘归一化 cos(latitude)，补偿等经纬网格在高纬区域的面积过采样，使每个格点贡献更接近真实球面面积。
T7	Muon + AdamW 分组优化	83 个骨干二维权重使用 Muon (lr=0.02, momentum=0.99)；patch embedding/recovery、偏置、归一化和尺度参数等 158 组使用 AdamW (lr=6e-4, wd=0.05, betas=0.9/0.95)。矩阵权重获得方向归一化更新，其余参数使用更稳健的逐元素更新。
T8	Warmup + 余弦退火	第一阶段 warmup 4 epoch 后余弦退火；第二阶段使用更小学习率 6e-5、warmup 2 epoch，再余弦下降。续训阶段降低步长，减少对已学教师能力的破坏。
T9	BF16 混合精度训练	教师前向和学生训练均使用 BF16 autocast，保留 FP32 损失计算与必要累加。BF16 指数范围较 FP16 更大，能减少高动态范围气象场中的溢出，同时降低训练显存和计算时间。
T10	EMA 权重	每个优化步后以 decay=0.999 更新学生指数滑动平均；验证与保存使用 EMA 模型，降低小批量和经度增强造成的参数抖动。
T11	梯度裁剪	每步更新前执行 clip_grad_norm_=1.0，限制少量极端天气样本或混合监督导致的梯度尖峰，保护 BF16 训练稳定性。
T12	经度周期 roll 增强	对输入、教师目标和真值沿经度轴做相同随机循环平移。经度本身周期闭合，该增强不改变物理关系，可减少模型对固定经度位置的过拟合。
T13	连续 6h pair 与固定验证切分	第二阶段只接受文件名时间差严格等于 6h 的相邻样本；当时 482 个有效 pair 经固定随机种子打乱，max_cache=300 后按末尾 10% 切为 270 训练、30 验证，避免跨时间步伪配对。
T14	严格续训与断点保存	第二阶段使用第一阶段权重并以 strict=True 加载；每个 epoch 写独立断点，保存结构 cfg、epoch、验证指标和 EMA 权重。最终使用 epoch 21 冻结快照转为推理权重。
T15	双口径验证监控	训练同时报告学生对教师的 val_match 与温度对真实 t+6h ERA5 的 RMSE：前者监控整体能力是否遗忘，后者监控真值校准是否生效。

最终配置中明确关闭的实验分支：输出残差预测、DTP 动态通道权重、物理特征头、频谱损失、全 15 指标真值监督、低层风湿额外真值监督、区域重加权和冻结 backbone 均为 o/关闭，不计入本方案的有效优化项。提交训练启动脚本会机械拒绝误开启这些分支。

五、推理优化（完整清单·最终版本）

下表为提交版本中全部生效的优化项，按其作用的评分维度分组。所有优化均为**数值等价变换**，不改变模型结构与预测目标。

A 组·推理时长优化（V）

#	优化项	说明与实测
A1	手写 HIP 算子路由前向 (maxvit3d_cpp.py)	将 torch 的 Linear / attention / RMSNorm / LayerNorm / SwiGLU 全部替换为自研 HIP kernel，消除 torch 算子的调度与中间张量开销。前向的全部计算均在官方计时区内执行。
A2	矩阵核 (MFMA) flash attention (src/attn_lib.hip)	用 gfx936 矩阵核指令 <code>__builtin_amdgcn_mmac_f32_16x16x16f16</code> 将 QK^T 与 AV 重写为 $16\times16\times16$ 的 tile 矩阵乘。原标量实现每线程串行 144 轮，仅发挥约 8% 算力。 实测 attention kernel 加速 $2.09\times$ (enc) / $1.84\times$ (mid) ，端到端前向 $32.3 \rightarrow 24.6$ ms 。
A3	矩阵核 GEMM (src/gemm_lib_mmac.hip)	自研 LDS 分块 GEMM，同样基于矩阵核指令，fp16 输入 / fp32 累加。不依赖 rocBLAS-Tensile（同时节省其常驻显存）。
A4	在线 softmax flash attention	注意力分数矩阵不物化到显存，在寄存器/LDS 内完成在线 softmax； <code>exp</code> 换底为硬件更快的 <code>exp2</code> （数学等价）。
A5	关闭 encoder fp32 残差流	原为防高激活权重 fp16 溢出而保留的 fp32 残差流；对本权重实测不需要（关闭后与 fp16 基线相对误差仍为 $4.1e-3$ 、无 NaN/Inf）， 省 1.9 ms 。
A6	计时区外预热	<code>gemm_init()</code> （hipBLAS handle 初始化）+ <code>micro_warmup</code> （预触发全部 kernel 的首次加载）+ 整分辨率 <code>warmup</code> ，均在官方计时区之外完成，消除首样本冷启动。
A7	CPU 侧数据预取	后台线程预取下一样本（dataloader 的 IO 与 numpy 操作多在 C 层释放 GIL），与当前样本的 DCU 计算重叠。
A8	inference_mode	替代 <code>no_grad</code> ，不建版本计数器，前向略快且更省。

B 组·轻量化 / 显存优化（U）

关键认识：官方明确显存按「推理过程中的采样均值」计分（排除启动阶段异常值）。因此**占用时长与占用峰值同等重要**——一块显存占得再高，只活几十毫秒，对均值影响很小；反之占得不高但横跨数百毫秒的存盘过程，会显著抬高均值。B1 与 B2 正是基于这一认识做出的，且被提交实测证实。

#	优化项	说明与实测
B1	输出先 D2H 、再在 CPU 上拼接，随后立即释放显存	原实现在 DCU 上 <code>concat</code> 输出会额外分配一份与输出等大的临时张量（约 143 MB），且它一直占着显存直到存盘结束（存盘是数百毫秒的纯 CPU 过程）。改为两路输出各自 D2H 后在 CPU 拼接，并在存盘之前释放显存。提交实测 U +1.27 。
B2	每样本 <code>empty_cache()</code>	在反归一化与 <code>np.save</code> （数百毫秒纯 CPU）之前释放 caching allocator。实测：不做此项，显存采样均值从 77 MB 飙升至 419 MB（而峰值完全相同）。
B3	CPU 上先 <code>.half()</code> 再 H2D	若写作 <code>invar.to('cuda').half()</code> ，PyTorch 会先把 65 通道的 fp32 整块搬上 DCU（约 270 MB）再转 fp16——该 fp32 中间张量正是显存峰值的真正来源。改为先在 CPU 转 fp16 再搬运。峰值 478 → 310 MB 。
B4	预分配输入 buffer ， H2D 直写切片	预分配 [1,72,721,1440] fp16 buffer，前 4 通道与后 65 通道在 buffer 内均连续，H2D 一次连续拷贝写入，不再产生 concat 副本。
B5	输入张量用完即释放	patch embedding 消费完输入后立即 <code>untyped_storage().resize_(0)</code> ，使其不再计入后续 backbone 与 recovery 阶段的显存。
B6	空间分块前向（ <code>N_TILES</code> ）	patch embedding 与 patch recovery 沿纬度分块流式处理，逐块计算并写入预分配输出，不物化完整中间张量。分块数经实测取 8（时长/峰值权衡点）。
B7	hipBLASLt 后端	ROCm 上 rocBLAS(Tensile) 库常驻显存约 212 MB，hipBLASLt 仅 109 MB。省约 103 MB （须在 <code>import torch</code> 前设置环境变量）。注：HIP 路由前向本身不触发 torch BLAS，此项主要保障回退路径。
B8	不物化注意力分数矩阵	flash attention 在线 softmax（见 A4）同时是显存优化：N×N 分数矩阵不落显存。
B9	<code>expandable_segments</code>	使 caching allocator 可伸缩、回收碎片，降低整体显存水位。
B10	fp16 权重与输入	模型权重 fp16 存储（10.46 MB），输入全程以 fp16 构造，避免 fp32 张量常驻。

C 组 · 精度保持（W）

#	优化项	说明与实测
C1	数值等价性校验	所有 HIP kernel 与 torch 基线逐元素比对：GEMM 为 bit-exact；矩阵核 attention 相对 torch fp32 参考的相对误差 6.9e-4（标量版为 2.8e-4，同一量级，均在 fp16 精度内）。 W 分在全部优化前后保持 38.4387 未变。
C2	bf16 / fp16 混合精度	前向以 fp16 计算、fp32 累加（矩阵核天然如此），保证精度不劣化。

D 组 · 合规工程（保证可复核）

#	优化项	说明
D1	HIP 算子现场编译	提交包内不含任何预编译二进制。HIP 源码（ <code>src/*.hip</code> ）随包提交，在评测机上用 <code>hipcc</code> 现场编译，实测两文件并行编译 3.1 秒 。编译产物写入可写目录（提交目录若为只读文件系统则自动落临时目录）。
D2	编译位于计时区外且显式完成	编译 + <code>dlopen</code> + 符号绑定在 warmup 之前由 <code>ensure_libs()</code> 显式一次性完成，绝不懒加载，不会把编译开销带入任何样本的计时区。（官方问答确认：只需编译一次，可放在计时范围外。）
D3	静态场融合置于计时区内	静态场（ <code>land_mask / soil_type / topography</code> ）与输入的融合属于数据预处理，按技术方案要求计入计时区。仅原始 69 通道输入的 H2D 搬运在计时区外（官方问答明确：原始输入加载到 DCU 的时间不计入推理时长）。
D4	优雅降级	若评测环境缺少编译工具链或编译失败，自动回退至纯 PyTorch 前向，保证评测 绝不崩溃 、结果正确。
D5	官方计时代码原位保留	<code>inference.py</code> 中 AI4S 计时代码位置未作任何改动，并按官方要求在模型前向后、计时结束前加入 <code>torch.cuda.synchronize()</code> 。

六、合规声明（逐条对照）

官方规定	本方案的做法	结论
禁止从零训练新模型（炼丹） 「直接从 o 开始训练新模型（炼丹）」→ 违规	学生权重完全由官方 Pangu 全量权重蒸馏得到 ：损失函数含教师监督项 $\alpha \cdot L1(\text{学生}, \text{教师输出})$ ，教师即官方 <code>model_bak.pth</code> （64.22M），全程冻结、只做前向、不训练、不替换。	符合
允许自研学生 + 蒸馏 「自己设计的学生模型...权重是通过 pangu 模型蒸馏出来的」→ 可以	本方案正属此类：自研 MaxViT-3D 结构，权重由官方教师蒸馏而来。学生结构与教师不同（MaxViT-3D vs Swin-3D），无法继承教师权重张量，故必然从随机初始化开始——这是蒸馏的固有形式，监督信号始终来自官方教师。	符合
限制使用任何第三方权重	全程仅使用官方提供的 Pangu 全量权重 作为教师。未使用 Pangu-lite 等任何其它预训练权重，未使用其他参赛队的代码、权重或二进制。	符合
数据集限制 「数据集中不提供除盘古模型输入外的其他气象信号」	训练与验证 仅使用组委会共享 ERA5 。829 个候选 H5 覆盖 1980-1997，逐年数量已在 3.1 节完整列出；最终第一阶段实际使用 300/13 个训练/验证样本，第二阶段实际使用 270/30 个连续 6h pair。实验室服务器仅是官方数据的同源镜像和计算载体。 未使用外部气象数据、隐藏测试集或额外气象要素 。	符合
量化边界 技术方案第 7 条 3(2)	推理阶段 不使用任何权重量化 ， 不生成可复用的量化权重缓存 。权重以 fp16 存储、fp16 计算 / fp32 累加。最终训练主干的缓存为普通 FP16 张量；此前 DCU 复刻中的 int8 缓存脚本不属于最终血缘，已从提交包删除。	符合
禁止投机解码等	本题题为单步气象场预测， 不存在投机解码 / MTP / 早退 / token 剪枝等机制 。	不适用
计时口径 技术方案 D44 第一条：数据预处理、数据/任务卸载代码须放入计时区内，不得利用计算卸载刻意绕过计时程序	前向的全部计算均在计时区内 ：静态场融合（数据预处理）置于计时区内；输入 H2D 在计时区外（官方问答明确允许）； 不存在把计算卸载到计时区外的行为 ——不做输出的计时区外重组、不做 CPU recovery offload、不做显存采样错位。计时代码位置未改动，并按官方要求补充了 <code>torch.cuda.synchronize()</code> 。	符合
提交内容不得含预编译二进制	提交包内无任何 <code>.so</code> / <code>.pyc</code> / 目标文件。HIP 算子以 源码 形式提交，在评测机上现场编译（实测 3.1 秒），编译命令与源码对应关系完整可查。	符合

不使用残差预测	学生直接输出绝对气象场，非「输入 + 增量」。权重配置 <code>residual: False</code> ，模型代码中无残差输出分支。	符合
不修改评测配置	<code>conf/config.yaml</code> （推理/评测配置，含 <code>test_ratio</code> 与结果路径）未作任何改动。实验室训练脚本通过独立命令行参数指定官方数据路径、年份和权重，不覆盖评测配置。	符合
运行环境	仅依赖赛方镜像已提供的 PyTorch / NumPy / OneScience / h5py / tqdm 与 DTK 工具链（hipcc）。未安装任何额外的第三方包。	符合

七、提交文件清单与复现说明

7.1 文件清单

文件	作用	类别
<code>inference.py</code>	推理入口（官方计时代码原位保留）	推理
<code>maxvit3d_student.py</code>	学生模型结构（训练与推理共用同一份，保证同构）	推理/训练
<code>maxvit3d_cpp.py</code>	HIP 算子路由前向 + 现场编译逻辑	推理
<code>src/attn_lib.hip</code>	矩阵核 flash attention + RMSNorm（HIP 源码）	推理
<code>src/gemm_lib_mmac.hip</code>	矩阵核 GEMM + LayerNorm + SwiGLU（HIP 源码）	推理
<code>conf/config.yaml</code>	官方推理/评测配置（未改动）	推理
<code>data/download_model_url.txt</code>	学生权重下载地址	推理
<code>data/checkpoints/student.pth</code>	轻量学生权重（随主包提交，可离线复核）	权重
<code>distill_cache.py</code>	4090 第一阶段真实脚本 （官方教师纯蒸馏 + Muon/AdamW + EMA）	训练
<code>distill_truth.py</code>	5090 第二阶段真实脚本 （14 温度通道加入官方 ERA5 真值监督）	训练
<code>muon.py</code>	第一阶段使用的 Muon 优化器实现	训练
<code>training/run_stage1_4090.sh / run_stage2_5090.sh</code>	两台实验室服务器对应的完整训练启动脚本	训练
<code>training/assets/metadata.json</code>	官方 ERA5 变量顺序元数据	训练资产
<code>build_hip.py</code>	HIP 源码显式编译入口	编译
<code>verify_submission.py</code>	必要文件、源码语法、权重和预编译文件自检	复核
<code>train.py / result.py</code>	赛方原始骨架（未改动）	骨架
<code>优化说明文档.md / README.md</code>	技术说明	文档

7.2 推理复现

解压后目录中已包含：data/checkpoints/student.pth

在赛方容器内：

```
source ../earth_env.sh
python verify_submission.py # 检查复核所需文件完整性
python build_hip.py          # 可选显式编译；inference.py 也会自动编译
python inference.py          # HIP 算子将自动现场编译（约 3 秒）
python result.py
```

7.3 训练复现

```
# 阶段 1: 实验室 Mitai 4090, 纯官方教师蒸馏
python distill_cache.py \
  --opt muon --muon-lr 0.02 --muon-momentum 0.99 \
  --global-mode grid --depths 2,4,2 --heads 6,12,6 \
  --embed 96 --patch 2,16,16 --mlp-ratio 2.0 \
  --train-years 1980,...,1996 --val-years 1997 \
  --epochs 80 --max-cache 300 --amp bf16 --aug 1 \
  --residual 0 --dtp 0 --spec 0 --save student_ratio2_mom99.pth

# 阶段 2: 实验室 abc66 5090, 从阶段 1 严格同结构续训
python distill_truth.py \
  --years 1980 --epochs 35 --max-cache 300 --val-frac 0.1 \
  --truth-alpha 0.5 --full-temp 1 --phys 0 --amp bf16 \
  --lr 6e-5 --warmup 2 --dtp 0 \
  --resume student_ratio2_mom99.pth --save student_truth_ft50.pth

# 实际使用 epoch 21 的冻结快照 snap_ft50_final.pth; 再转为 FP16 推理权重。
```

宁静致远 · 先导杯 2026 AI4S 赛题二「气象大模型轻量化」

本文档所载全部实测数据均来自真实运行记录。教师模型为官方提供的 Pangu-Weather 全量权重，全程冻结仅作前向；学生模型由官方教师蒸馏并使用官方 ERA5 做有限真值校准；训练与验证未使用任何组委会未授权数据。实验室 4090/5090 仅为训练算力和官方数据镜像载体。